

PROJE ANALİZ RAPORU

ENTITY NORMALIZATION & CONTEXT-AWARE SPELL CORRECTION

1. PROJE KONUSU

Bu proje, İngilizce haber akışındaki metinlerde yer alan özel isimler (Named Entities) ve genel İngilizce kelimelerdeki yazım hatalarının otomatik olarak tespit edilmesi ve bağlama duyarlı şekilde düzeltilmesini amaçlamaktadır.

Sistem, özellikle politik figürler, kurumlar, ülkeler ve coğrafi adlar gibi özel isimlerde meydana gelen deformasyonları dilin fonetik yapısına ve uluslararası standartlara uygun biçimde normalize ederken; aynı zamanda genel İngilizce kelimelerdeki tipografik ve ortografik hataları da bağlamı koruyarak düzeltmeyi hedeflemektedir.

2. PROBLEM TANIMI

Dijital haber üretim süreçlerinde hız baskısı, klavye uyumsuzluğu, çok dilli içerik üretimi ve otomatik veri akışları nedeniyle hem özel isimlerde hem de genel İngilizce kelimelerde ciddi yazım deformasyonları meydana gelmektedir.

Bu deformasyonlar:

- Haber içeriklerinin doğruluğunu ve güvenilirliğini azaltmakta,
- Arama motoru optimizasyonunu (SEO) olumsuz etkilemekte,
- Bilgi erişim sistemlerinde eşleşme hatalarına yol açmakta,
- Metin madenciliği ve veri analitiği süreçlerinde veri bütünlüğünü bozmaktadır.

Bunun yanı sıra, bu tür hatalar haber kaynağına duyulan güveni ve kaynağın sahip olduğu prestiji de sarsabilecek küçük ama medya sektöründeki firmalar için büyük etkiler doğuran itibar riskleri oluşturmaktadır. Bu nedenle hem özel isim normalizasyonu hem de genel bağlama duyarlı yazım düzeltmesi yapabilen bütünlük bir sisteme ihtiyaç duyulmaktadır.

3. YAZIM HATALARI SINIFLANDIRMASI

Haber metinlerinde karşılaşılan yazım hataları altı temel kategoride ele alınmaktadır.

1) De-asciification (Karakter Dönüşümü)

Türkçe karakterlerin İngilizce klavye uyumluluğu nedeniyle ASCII karakterlere indirgenmesi veya yanlış dönüştürülmesi durumudur.

- Karakter Değişimi:** u→ü, o→ö, s→ş, g→ğ, c→ç gibi spesifik harf kayıpları.
- Noktalama ve Büyük/Küçük Harf Hataları:** İngilizce ve Türkçe arasındaki i→İ ve l→ı (noktalı/noktasız) karmaşası.
- Örnekler:** Türkiye → Türkiye, İstanbul → İstanbul, TURKIYE → TÜRKİYE.

2) Harf Dizilimi ve Tipografik Hatalar

- **Harf Eksikliği (Omission):** Karakterlerin metinden düşmesi (Örn: Erdogan → Erdgan, President → Prsident).
- **Harf Fazlalığı (Insertion):** Gereksiz karakter eklenmesi (Örn: Türkiye → Türkiyee, Political → Poliitcal).
- **Yer Değiştirme (Transposition):** Harflerin sırasının karışması (Örn: Süleyman → Sülyeman, Israeli → Irsaeli).
- **Yanlış Harf (Substitution):** Klavyede komşu olan veya benzer sesli yanlış harf kullanımı (Örn: Ankara → Abkara, Taliban → Takiban).
- **Birleşik/Ayrı Yazım Hataları:** Özel isimler arasındaki boşluk karakterinin kaybı (Örn: Abdullah Gül → AbdullahGül, New York → NewYork).

3) Uluslararası İsim Değişimleri (Terminoloji)

Ülkelerin veya kurumların uluslararası alanda talep ettiği resmi isim değişikliklerinin takibi ve eski kullanımların güncellenmesi sorunudur.

- **Örnekler:** Turkey → Türkiye (2022 sonrası), Burma → Myanmar, Swaziland → Eswatini.

4) Genel İngilizce Yazım Hataları (Lexical Spelling Errors)

Özel isim olmayan standart İngilizce kelimelerde görülen ortografik hatalardır.

- goverment → government
- enviroment → environment
- politcal → political
- recieve → receive

Bu hatalar bağlama duyarlı biçimde düzeltilmelidir. Çünkü bazı kelimeler doğru yazıldığında farklı anlamlara gelebilir veya isimlerle karışabilir.

5) Gramer ve Sözdizimi Hataları (Grammar & Syntax Errors)

Haber metninin akışını ve anlamını bozan yapısal dil bilgisi hatalarıdır.

- **Eksik Artikeller ve Edatlar:** "a, an, the" gibi artikellerin veya "in, on, at" gibi edatların eksikliği veya yanlış kullanımı.
- **İyelik Ekleri (Possessives):** Özel isimlere gelen mülkiyet eklerinin hatalı kullanımı.
- **Özne-Yüklem Uyumu ve Çatı Hataları:** Özne ile yüklem arasındaki sayı/şahıs uyumsuzlukları ve etken/edilgen (passive voice) yapı dönüşümleri.
- **Örnekler:** "struck" → "were struck", "Türkiye ascension" → "Türkiye's accession".

6) Noktalama İşaretleri Hataları (Punctuation Errors)

Cümle sınırlarının belirlenmesi ve metin içi duraklamaların düzenlenmesi için kritik olan işaretlerin eksikliği veya yanlış kullanımıdır.

- **Cümle Sınırı Restorasyonu:** Cümle sonlarında unutulmuş noktaların ve büyük harf geçişlerinin düzeltilmesi.
- **Anlam Karışıklığını Önleyen Virgüller:** Bağlamı netleştirmek için gerekli olan virgül ve diğer işaretlerin (comma, semicolon vb.) eklenmesi
- **Örnekler:** Cümle sonuna eksik nokta konulması, sıralı isimler arasına virgül eklenmesi.

4. PROBLEM KISITLARI (CONSTRAINTS)

Projenin başarısı için aşılması gereken temel teknik kısıtlar şunlardır:

1) Cümle Yapısının ve Bağlamın Korunması

İngilizce dil bilgisi yapısı bozulmamalıdır. Sistem yalnızca hatalı yazımları düzeltmeli, doğru kelimelere müdahale etmemelidir.

2) Seçici Müdahale (Entity vs Non-Entity Ayrımı)

Sistem, özel isimleri ve genel kelimeleri doğru şekilde ayırt ederek her biri için uygun düzeltme stratejisini uygulamalıdır.

3) OOV (Out-of-Vocabulary) Kapasitesi

Eğitim verisinde bulunmayan yeni kişi, kurum veya yer adları karakter yapısından ve fonetik benzerlikten yararlanılarak tanınabilmelidir.

4) Dile Bağlı Belirsizlik (Ambiguity)

Bazı kelimeler hem özel isim hem de genel kelime olabilir (May, Bill, Brown vb.). Sistem bağlamı analiz ederek doğru yorumu seçmelidir.

5) Over-Correction Riskinin Önlenmesi

Haber metinlerinde yanlış düzeltme ciddi anlam kaymalarına neden olabilir. Sistem gereksiz müdahaleden kaçınmalı ve yüksek güven eşiği ile çalışmalıdır. Yanlış pozitif düzeltmeler, doğru yazılmış bir özel ismi bozma riski taşıdığından, sistemin hata toleransı düşük tutulmalıdır.

6) Çok Dilli Etkileşim

Metinler İngilizce olmakla birlikte Türkçe karakterler ve farklı dil kökenli isimler içerebilir. Sistem çok dilli karakter yapılarıyla uyumlu çalışmalıdır.

7) Tutarlılık ve Standartlaştırma

Aynı varlık metnin farklı bölümlerinde aynı biçimde normalize edilmelidir.

8) Gerçek Zamanlı İşlenebilirlik

Haber akışları yüksek hacimli olduğundan sistem ölçeklenebilir ve hızlı çalışmalıdır.

5. PROJENİN HEDEF ÇIKTISI

Geliştirilecek sistem:

- Metindeki hatalı özel isimleri doğru biçime normalize eder,
- Genel İngilizce yazım hatalarını bağlama duyarlı şekilde düzeltir,
- Cümle yapısını korur,
- Terminolojik standartları uygular,
- Veri bütünlüğünü ve metin güvenilirliğini artırır,
- Medya kuruluşlarının yayın kalitesi ve kurumsal itibarını korumasına katkı sağlar.

Sonuç olarak proje, haber metinlerinde yüksek doğruluklu otomatik metin standardizasyonu sağlayan bütünlüklü bir dil işleme sistemi ortaya koymayı amaçlamaktadır.